

# ANALISIS PERBANDINGAN ALGORITMA DECISION TREE, RANDOM FOREST, KNN, DAN SVM DALAM PREDIKSI PENYAKIT JANTUNG

Muhammad Muttakin<sup>1</sup>, Najwa Rokhan Rusmana<sup>1</sup>, Dian Ramadhani<sup>1\*</sup>

<sup>1</sup>Dept. of Informatics Engineering, Faculty of Engineering, Universitas Riau, Pekanbaru, Indonesia  
muttakin2418@gmail.com, roesmana2803@gmail.com, dianramadhani@lecturer.unri.ac.id

\*Corresponding author: dianramadhani@lecturer.unri.ac.id

**Abstract:** Penyakit jantung adalah masalah kesehatan serius global, menyebabkan 9,4 juta kematian tiap tahun dan diperkirakan meningkat hingga 23,3 juta pada 2030. Kurangnya deteksi dini dan gaya hidup tidak sehat menjadi faktor utama meningkatnya kasus, terutama di negara berkembang. Penelitian ini bertujuan mengembangkan sistem prediksi risiko penyakit jantung yang akurat dan efisien sebagai dukungan diagnosis dini. Metode yang digunakan melibatkan empat algoritma klasifikasi, yaitu Decision Tree, Random Forest, K-Nearest Neighbors (KNN), dan Support Vector Machine (SVM). Salah satu tantangan terbesar dalam machine learning adalah overfitting, yaitu ketika model tidak mampu menggeneralisasi dengan baik dari data pelatihan ke data baru yang dievaluasi berdasarkan akurasi, precision, dan F1-score serta cross validation. Pada penelitian ini, hasil evaluasi menunjukkan Decision Tree dan Random Forest memiliki akurasi terbaik yaitu mencapai 99%, sedangkan KNN dan SVM memiliki akurasi masing-masing 84% dan 88%. Dengan demikian, Decision Tree dan Random Forest direkomendasikan sebagai model terbaik untuk prediksi risiko penyakit jantung yang menunjukkan potensi tinggi untuk dukungan keputusan klinis. Berdasarkan evaluasi menggunakan cross validation menunjukkan tidak ada indikasi overfitting pada keempat model. Skor yang konsisten dan standar deviasi rendah menandakan kemampuan generalisasi yang baik. Untuk meningkatkan hasil di penelitian selanjutnya, disarankan agar dataset diperbanyak dan lebih beragam, serta dilakukan optimalisasi model melalui hyperparameter tuning agar performa prediksi semakin akurat dan andal.

**Keywords—***Algoritma Klasifikasi, Jantung, Prediksi, Risiko, SVM*

## I. PENDAHULUAN

Penyakit jantung merupakan salah satu masalah kesehatan paling serius yang dihadapi masyarakat global saat ini. Gangguan pada sistem kardiovaskular tidak hanya berdampak pada kualitas hidup penderitanya, tetapi juga menjadi penyebab utama kematian di berbagai negara. Berdasarkan statistik dunia, setiap tahunnya terdapat sekitar 9,4 juta kematian yang disebabkan oleh penyakit jantung (cardiovascular disease), menjadikannya salah satu penyebab kematian tertinggi secara global. Tren ini menunjukkan peningkatan yang signifikan, dengan prediksi bahwa angka kematian akibat penyakit jantung akan terus meningkat hingga mencapai 23,3 juta kasus per tahun pada tahun 2030 [1].

Penyebab utama penyakit jantung sangat berkaitan dengan gaya hidup yang tidak sehat, seperti konsumsi makanan tinggi lemak dan gula, kurangnya aktivitas fisik, kebiasaan merokok, konsumsi alkohol, dan stres berkepanjangan. Padahal, sebagian besar kasus penyakit jantung dapat dicegah melalui deteksi dini dan pengendalian faktor risiko. Deteksi awal sangat penting, terutama bagi individu dengan riwayat keluarga, untuk mencegah komplikasi serius hingga kematian yang sebenarnya dapat dicegah [2].

Kurangnya pemahaman gejala awal penyakit jantung dan minimnya gaya hidup sehat membuat banyak orang tidak menyadari risikonya. Deteksi ini berperan sebagai dukungan dalam pengambilan keputusan untuk menjaga kesehatan. Dengan pemeriksaan rutin, risiko penyakit jantung dapat diketahui sejak dini sehingga penanganan lebih tepat dan biaya pengobatan lebih efisien [3]. Oleh sebab itu, diperlukan sistem deteksi penyakit jantung yang

dapat memberikan hasil yang akurat sekaligus lebih efisien bagi masyarakat agar terhindar dari kondisi yang lebih buruk di masa depan [4].


Dalam mendeteksi penyakit jantung, digunakan berbagai metode seperti stress echocardiography, cardiac CT scan, myocardial perfusion imaging, dan coronary CT angiography (CCTA) untuk menilai fungsi jantung, aliran darah, serta kelainan struktural dan penyumbatan arteri koroner. Kombinasi berbagai modalitas ini penting dalam evaluasi penyakit jantung iskemik, karena meningkatkan akurasi diagnosis dan membantu menentukan perlunya angiografi koroner [5].

Salah satu tantangan terbesar dalam machine learning adalah overfitting, yaitu ketika model tidak mampu menggeneralisasi dengan baik dari data pelatihan ke data baru [6]. Oleh karena itu, algoritma decision tree, random forest, KNN, dan SVM akan dievaluasi menggunakan confusion matrix dan cross-validation sebagai metode evaluasi untuk mendeteksi terjadinya overfitting pada algoritma machine learning [7][8]. Tujuannya adalah untuk mengevaluasi performa masing-masing algoritma dalam mendeteksi penyakit jantung secara dini dan akurat, sehingga dapat mendukung proses diagnosis yang lebih efisien dan mudah diimplementasikan dalam sistem layanan Kesehatan.

## II. METODOLOGI PENELITIAN

Penelitian ini menggunakan beberapa algoritma machine learning untuk dilakukan perbandingan performa dalam pengklasifikasian risiko penyakit jantung, yaitu Support Vector Machine, K-Nearest Neighbors, Decision Tree dan Random Forest. Gambar 1 menunjukkan tahapan

penelitian perbandingan algoritma klasifikasi yang digunakan.



Gambar 1. Tahapan penelitian

Berdasarkan Gambar 1 penelitian ini bertujuan untuk membandingkan performa beberapa algoritma klasifikasi machine learning dalam membangun model prediksi risiko penyakit jantung. Dataset yang digunakan berasal dari Kaggle yang berisi atribut klinis seperti usia, tekanan darah, kadar kolesterol, dan variabel lainnya yang relevan. Setelah data diperoleh, dilakukan tahap preprocessing untuk membersihkan dan menyiapkan data melalui proses cleansing, normalisasi, dan transformasi data kategorikal menjadi numerik. Data yang telah diproses kemudian dibagi menjadi data latih dan data uji untuk memastikan hasil evaluasi yang lebih akurat dan menghindari overfitting. Model klasifikasi kemudian dibangun menggunakan empat algoritma machine learning, yaitu Decision Tree, Random Forest, K-Nearest Neighbors, dan Support Vector Machine, yang masing-masing memiliki keunggulan dalam mengenali pola dari data latih. Setelah pelatihan, model digunakan untuk memprediksi data uji, dan hasil prediksi dievaluasi menggunakan Confusion Matrix dan cross validation.

#### A. Studi Literatur

Pada studi literatur ini, dibahas berbagai konsep dan temuan terkait penerapan algoritma machine learning dalam mendeteksi penyakit jantung. Salah satu tantangan utama yang sering muncul dalam pengembangan model adalah overfitting, yaitu kondisi ketika model tidak mampu menggeneralisasi dengan baik dari data pelatihan ke data baru [6]. Untuk mengatasinya, proses preprocessing data dilakukan agar data menjadi bersih, konsisten, dan siap digunakan dalam pelatihan model [9]. Lalu pemilihan evaluasi confusion matrix dan cross-validation sebagai metode evaluasi untuk mendeteksi terjadinya overfitting pada algoritma machine learning [7][8].

#### B. Data Collecting

Dataset yang digunakan dalam penelitian ini merupakan data sekunder dari Kaggle, khususnya heart disease dataset. Dataset ini memuat informasi klinis dari pasien seperti usia, jenis kelamin, tipe nyeri dada, tekanan darah istirahat, kolesterol, gula darah puasa, hasil EKG istirahat, denyut jantung maks, angina terinduksi olahraga,

depresi st, kemiringan st, jumlah pembuluh berwarna, jenis thalasemia, dengan label target yang menunjukkan ada atau tidaknya indikasi penyakit jantung.

#### C. Preprocessing Data

Data mentah yang diperoleh dari berbagai sumber seringkali mengandung ketidakkonsistenan, nilai yang hilang, duplikasi, dan noise yang dapat merusak akurasi prediksi model. Tanpa tahap preprocessing, model AI akan kesulitan mengenali pola yang benar dan bisa menghasilkan kesimpulan yang menyesatkan. Preprocessing juga membantu mengurangi risiko overfitting, meningkatkan generalisasi terhadap data baru, serta mempercepat proses pelatihan model dengan data yang lebih ringkas dan relevan [9].

Penggunaan StandardScaler bertujuan untuk menyamakan skala setiap fitur agar memiliki rata-rata nol dan deviasi standar satu. Hal ini mencegah fitur dengan rentang nilai besar mendominasi perhitungan jarak, sehingga model menjadi lebih stabil, akurat, dan mampu melakukan generalisasi dengan lebih baik [10].

#### D. Decision Tree

Algoritma Decision Tree adalah metode klasifikasi yang membagi data ke dalam struktur pohon berdasarkan nilai atribut tertentu, menggunakan perhitungan entropy dan information gain untuk menentukan atribut mana yang paling baik membagi data pada setiap node. Proses ini berlangsung secara rekursif hingga semua data terklasifikasi atau tidak dapat dibagi lagi. Decision Tree bersifat intuitif dan mudah dipahami, karena menyerupai logika pengambilan keputusan manusia. Struktur pohon terdiri dari node keputusan (decision nodes), cabang (branches), dan daun (leaves) yang masing-masing mewakili kondisi dan hasil klasifikasi akhir [11]. Rumus information gain adalah berikut.

$$\text{Gain}(A) = \text{Entropy}(D) - \sum_{j=1}^n p_j \cdot \text{Entropy}(D_j) \quad (1)$$

di mana  $D$  adalah dataset awal,  $D_j$  adalah subset data setelah dibagi berdasarkan nilai atribut  $A$ , dan  $p_j$  adalah proporsi data pada subset  $D_j$  [12].

Salah satu kelemahan utama dari algoritma Decision Tree adalah kecenderungannya mengalami overfitting, terutama ketika pohon tumbuh terlalu dalam dan kompleks. Dalam kondisi ini, model terlalu menyesuaikan diri dengan data pelatihan, bahkan sampai menangkap noise atau pola yang tidak relevan. Akibatnya, meskipun akurasinya tinggi pada data pelatihan, performa model dapat menurun drastis saat diuji pada data baru karena kehilangan kemampuan generalisasi. Hal ini membuat Decision Tree kurang andal jika digunakan tanpa pengendalian kompleksitas model secara tepat [13].

#### E. Random Forest

Random Forest adalah algoritma machine learning berbasis ensemble yang digunakan untuk tugas klasifikasi dan regresi, dengan membangun banyak pohon keputusan (decision trees) secara acak lalu menggabungkan hasilnya. Setiap pohon dilatih dengan teknik bootstrap sampling

mengambil sampel acak dari data latih dengan pengembalian dan hanya sebagian fitur yang dipilih secara acak di setiap node, yang disebut feature randomness. Kombinasi hasil klasifikasi dari seluruh pohon dilakukan melalui voting mayoritas (untuk klasifikasi) atau rata-rata (untuk regresi). Pendekatan ini membuat Random Forest tangguh terhadap overfitting dan efektif dalam menangani data yang kompleks dan berdimensi tinggi [14]. Prediksi akhir ensemble dihitung sebagai rata-rata prediksi dari semua pohon regresi.

$$\mu_{bag}(x) = \frac{1}{B} \sum_{b=1}^B \mu^{*b}(x) \quad (2)$$

di mana B adalah jumlah pohon dan  $\mu_{bag}(x)$  adalah prediksi pohon ke-b dalam bentuk input X [15].

Salah satu kekurangan utama dari algoritma Random Forest adalah tingkat kompleksitas dan kurangnya interpretabilitas. Meskipun Random Forest merupakan kumpulan dari banyak decision tree dan unggul dalam akurasi prediksi, struktur internalnya yang terdiri dari ratusan atau bahkan ribuan pohon membuatnya sulit untuk dipahami secara menyeluruh oleh manusia. Hal ini menjadikannya sebuah "black-box model", di mana proses pengambilan keputusan sulit dilacak atau dijelaskan, terutama dalam konteks aplikasi yang membutuhkan transparansi tinggi seperti bidang medis, hukum, atau keuangan. Kesulitan dalam menjelaskan hasil prediksi kepada pengguna non-teknis sering kali menjadi penghalang dalam adopsi model ini di dunia nyata [16].

#### F. K-Nearest Neighbors

K-Nearest Neighbors (KNN) adalah algoritma supervised learning untuk klasifikasi dan regresi yang bekerja dengan mencari K tetangga terdekat berdasarkan jarak, biasanya Euclidean. Kelas data uji ditentukan dari mayoritas tetangga tersebut. Sebagai lazy learner, KNN tidak membangun model sebelumnya dan sangat bergantung pada data pelatihan. Kelebihannya meliputi kesederhanaan, kemampuan menangani data non-linear, dan fleksibilitas penggunaan. Pemilihan nilai K, normalisasi, dan pembersihan data sangat penting untuk hasil optimal [17]. Pada KNN Kedekatan didefinisikan dalam hal metrik jarak, seperti jarak Euclidean. Jarak Euclidean antara dua titik atau tuple, katakanlah,  $X1 = (x11, x12, \dots, x1n)$  dan  $X2 = (x21, x22, \dots, x2n)$ , adalah [18]

$$d(x, x_i) = \sqrt{\sum_{j=1}^n (x_j - x_{ij})^2} \quad (3)$$

Algoritma ini memiliki sejumlah kelemahan, di antaranya adalah kebutuhan komputasi yang tinggi karena harus menghitung jarak ke seluruh data latih untuk setiap prediksi. Selain itu, KNN sensitif terhadap outlier dan noise, yang dapat memengaruhi hasil klasifikasi secara signifikan. Algoritma ini juga cenderung bias terhadap kelas mayoritas pada data yang tidak seimbang, serta kurang efektif saat digunakan pada data berdimensi tinggi karena mengalami penurunan akurasi akibat "curse of dimensionality" [19].

#### G. Support Vector Machine

Support Vector Machine (SVM) adalah algoritma pembelajaran mesin yang digunakan untuk tugas klasifikasi dan regresi. Konsep utama SVM adalah mencari hyperplane terbaik yang dapat memisahkan dua kelas data secara maksimal. Dalam kasus data yang tidak dapat dipisahkan secara linear, SVM menggunakan fungsi kernel seperti Radial Basis Function (RBF) untuk memetakan data ke dalam ruang berdimensi lebih tinggi sehingga menjadi dapat dipisahkan. Tujuan utama SVM adalah memaksimalkan margin, yaitu jarak antara hyperplane dengan data dari masing-masing kelas, guna meningkatkan kemampuan generalisasi model [20]. Formulasi matematis dari SVM dapat dituliskan sebagai

$$\min_{w,b} \frac{1}{2} |w|^2 \text{ dengan syarat } y_i(w \cdot x_i + b) \geq 1 \quad (4)$$

di mana  $w$  adalah vektor bobot,  $b$  adalah bias, dan  $y_i$  adalah label dari data ke-i [21].

Support Vector Machine (SVM) sensitif terhadap pemilihan parameter, seperti nilai C dan kernel, yang sangat memengaruhi akurasi. Proses tuning parameternya memakan waktu dan memerlukan optimisasi yang kompleks. SVM kurang efektif untuk dataset besar dan rawan overfitting jika terdapat noise. Selain itu, SVM tidak optimal untuk data yang tidak dapat dipisahkan secara linier tanpa transformasi kernel yang rumit [22].

#### H. Confusion Matrix

Confusion matrix adalah sebuah tabel yang digunakan untuk mengevaluasi kinerja model klasifikasi dalam machine learning dengan membandingkan hasil prediksi model terhadap label aktual (ground truth). Tabel ini menyajikan informasi tentang jumlah prediksi yang benar dan salah untuk setiap kelas, sehingga memudahkan dalam menghitung metrik evaluasi seperti akurasi, presisi, recall, dan F1-score. Penghitungan metrik evaluasi seperti akurasi, presisi, recall, dan F1-score dilakukan dengan menggunakan rumus-rumus berikut [23].

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

$$Precision = \frac{TP}{TP + FP} \quad (6)$$

$$Recall = \frac{TP}{TP + FN} \quad (7)$$

$$F1 - score = \frac{2(Precision \times Recall)}{Precision + Recall} \quad (8)$$

Dalam deteksi penyakit jantung, metrik seperti akurasi, presisi, dan recall membantu menilai seberapa baik model mengenali pasien yang benar-benar sakit dan yang sehat.

#### I. Cross Validation

Dalam cross-validation, standard deviation antar-fold mencerminkan stabilitas performa model terhadap variasi data. Jika seluruh fold menghasilkan skor identik, seperti akurasi 1.0000 dengan deviasi 0.0000, hal ini mengindikasikan model mungkin telah menghafal data pelatihan, bukan belajar pola yang dapat digeneralisasi. Kondisi ini mencerminkan potensi overfitting, terutama pada data yang sederhana atau kecil [8].

Deviasi nol menunjukkan bahwa model tidak mengalami variasi evaluasi antar subset data, yang seharusnya terjadi secara alami pada data nyata. Oleh karena itu, performa yang terlalu sempurna dan konsisten dalam cross-validation menjadi indikator overfitting, dan memerlukan pengaturan ulang model atau penerapan regularisasi untuk meningkatkan generalisasi [7].

### III. HASIL DAN PEMBAHASAN

Penelitian ini dimulai dengan tahap pengumpulan dan eksplorasi data dari situs Kaggle yang berisi informasi medis terkait risiko penyakit jantung. Proses preprocessing dilakukan untuk memastikan data bersih, terstruktur, dan siap digunakan dalam analisis lanjutan, termasuk normalisasi dan seleksi fitur yang relevan. Selanjutnya, berbagai algoritma klasifikasi diterapkan dan dibandingkan untuk menentukan model terbaik dalam memprediksi risiko penyakit jantung berdasarkan performa akurasi, presisi, recall, dan F1-score serta cross validation.

#### A. Data Collecting

Tahap pertama yaitu pengumpulan data dimana data diambil dari situs Kaggle. Informasi data terdiri dari 1025 data, variabel target 0 menunjukkan bahwa penderita penyakit jantung dan variabel target 1 merupakan bukan penderita jantung. Berikut adalah fitur pada dataset penyakit jantung.

Tabel 1. Data Fitur Penyakit Jantung

|      | age | sex | cp  | trestbps | ... | target |
|------|-----|-----|-----|----------|-----|--------|
| 1    | 6   | 148 | 72  | 125      | ... | 0      |
| 2    | 1   | 85  | 66  | 140      | ... | 0      |
| 3    | 8   | 183 | 64  | 145      | ... | 0      |
| 4    | 1   | 89  | 66  | 148      | ... | 0      |
| ...  | ... | ... | ... | ...      | ... | ...    |
| 1024 | 62  | 0   | 0   | 138      | ... | 0      |

Tabel 1 menunjukkan dataset penyakit jantung yang mencakup berbagai fitur, seperti. Di bawah ini adalah penjelasan singkat tentang masing-masing fitur:

- 1) age: usia pasien
- 2) sex: jenis kelamin (0 = perempuan, 1 = laki-laki)
- 3) cp: tipe nyeri dada (indikasi kemungkinan penyakit jantung)
- 4) trestbps: tekanan darah saat istirahat (mm Hg)
- 5) chol: kadar kolesterol total dalam darah (mg/dl)
- 6) fbs: gula darah puasa > 120 mg/dl (1 = ya, 0 = tidak)
- 7) restecg: hasil EKG saat istirahat (elektrokardiografi)
- 8) thalach: denyut jantung maksimum yang dicapai
- 9) exang: angina (nyeri dada) yang dipicu oleh olahraga (1 = ya, 0 = tidak)
- 10) oldpeak: tingkat depresi segmen ST dibandingkan saat istirahat
- 11) slope: kemiringan segmen ST selama latihan (menurun, datar, naik)
- 12) ca: jumlah pembuluh darah besar yang terlihat melalui fluoroskopi
- 13) thal: jenis thalasemia (kelainan darah bawaan)

Data tersebut sangat berguna untuk membantu memahami kondisi kesehatan dan mendukung proses diagnosis. Dengan mengetahui fitur-fitur tersebut, analisis dan pengambilan keputusan yang tepat terkait penyakit jantung dapat dilakukan dengan lebih baik.

#### B. Preprocessing Data

Proses preprocessing dimulai dengan eksplorasi awal dataset untuk memahami struktur dan karakteristik data. Fungsi info() dan describe() digunakan untuk melihat tipe data serta statistik deskriptif, sementara pengecekan nilai hilang memastikan dataset bersih dan siap diproses. Selanjutnya, nama kolom diganti agar lebih mudah dipahami, misalnya age menjadi usia dan sex menjadi jenis kelamin seperti pada Tabel 2.

Tabel 2. Data penyakit jantung setelah mengganti kolom

|      | usia | jenis kelamin | tipe nyeri dada | ... | target |
|------|------|---------------|-----------------|-----|--------|
| 0    | 52   | 1             | 0               | ... | 0      |
| 1    | 53   | 1             | 0               | ... | 0      |
| 2    | 70   | 1             | 0               | ... | 0      |
| 3    | 61   | 1             | 0               | ... | 0      |
| ...  | ...  | ...           | ...             | ... | ...    |
| 1024 | 54   | 1             | 0               | ... | 0      |

Analisis korelasi untuk mengetahui hubungan antar fitur pada Tabel 2 dengan variabel target. Hasilnya menunjukkan fitur seperti denyut jantung maksimum dan tipe nyeri dada memiliki korelasi tinggi dan penting untuk model prediksi. Berdasarkan analisis dan referensi medis, dilakukan seleksi fitur untuk memilih atribut paling relevan agar model lebih efisien dan akurat.

Tabel 3. Korelasi antar fitur terhadap variabel target

| Fitur                      | Target |
|----------------------------|--------|
| Usia                       | -0,23  |
| Jenis kelamin              | -0,28  |
| Tipe nyeri dada            | 0,43   |
| Tekanan darah istirahat    | -0,14  |
| Kolesterol                 | -0,10  |
| Gula darah puasa           | -0,04  |
| Hasil EKG istirahat        | 0,13   |
| Denyut jantung maks        | 0,42   |
| Angina terinduksi Olahraga | -0,44  |
| Depresi st                 | -0,44  |
| Kemiringan st              | 0,35   |
| Jumlah pembuluh berwarna   | -0,38  |
| Jenis thalasemia           | -0,34  |

Berdasarkan Tabel 3, dipilih beberapa fitur yang memiliki korelasi tertinggi terhadap variabel target yaitu tipe nyeri dada, angina terinduksi olahraga, depresi st, jenis thalasemia, denyut jantung maks, jumlah pembuluh berwarna dan usia. Lalu, Data numerik kemudian dinormalisasi menggunakan StandardScaler, yang mengubah nilai-nilai menjadi distribusi dengan rata-rata (mean) 0 dan standar deviasi 1. Proses normalisasi ini penting terutama untuk algoritma berbasis jarak, seperti K-Nearest Neighbors (KNN) dan Support Vector Machine (SVM), karena dapat mempercepat konvergensi dan meningkatkan kestabilan serta akurasi model.

Berdasarkan Tabel 4, Dengan melakukan normalisasi data menggunakan StandardScaler, fitur-fitur numerik pada dataset penyakit jantung telah berhasil diubah menjadi skala yang seragam dengan rata-rata nol dan standar deviasi satu. Transformasi ini tidak hanya



meningkatkan performa algoritma berbasis jarak seperti KNN dan SVM, tetapi juga memastikan proses pelatihan model menjadi lebih stabil dan efisien. Hasil transformasi yang terlihat pada Tabel 4 menggambarkan bagaimana nilai-nilai fitur kini lebih konsisten dan siap untuk analisis lebih lanjut guna mendukung prediksi yang akurat terhadap kondisi penyakit jantung.

*Tabel 4. Data fitur penyakit jantung setelah ditransformasi*

|      | Angina terinduksi olahraga | Depresi st | ... | target |
|------|----------------------------|------------|-----|--------|
| 0    | 0                          | -0.060888  | ... | 0      |
| 1    | 1                          | 1.727137   | ... | 0      |
| 2    | 1                          | 1.301417   | ... | 0      |
| 3    | 0                          | -0.912329  | ... | 0      |
| ...  | ...                        | ...        | ... | ...    |
| 1024 | 0                          | 0.279688   | ... | 0      |

*Tabel 5. Train-test split ratio*

| Data  | Persentase | Jumlah |
|-------|------------|--------|
| Train | 80%        | 820    |
| Test  | 20%        | 205    |

Berdasarkan Tabel 5 tersebut menunjukkan pembagian dataset menjadi dua bagian, yaitu data train dan test. Sebanyak 80% dari total data, yaitu 820 data, digunakan sebagai data train untuk melatih model agar dapat mengenali pola dan melakukan pembelajaran. Sementara itu, sisanya sebesar 20%, yaitu 205 data, digunakan sebagai data test untuk menguji kinerja model setelah proses pelatihan.


#### C. Klasifikasi dengan Algoritma Decision Tree

Pada tahap ini, dilakukan proses klasifikasi menggunakan algoritma Decision Tree untuk memprediksi kemungkinan seseorang terkena penyakit jantung. Evaluasi performa model dilakukan dengan menggunakan metrik-metrik evaluasi seperti precision, recall, dan F1-score.

*Tabel 6. Evaluasi model Decision Tree*

|              | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0            | 0,97      | 1,00   | 0,99     | 102     |
| 1            | 1,00      | 0,97   | 0,99     | 103     |
| Accuracy     |           |        | 0,99     | 205     |
| Macro avg    | 0,99      | 0,99   | 0,99     | 205     |
| Weighted avg | 0,99      | 0,99   | 0,99     | 205     |

Hasil evaluasi kinerja model pada Tabel 6 menunjukkan bahwa model Decision Tree memiliki performa sangat tinggi, dengan akurasi 0,99, precision sempurna (1,00) untuk kelas positif, recall mencapai 0,99 dan F1-score yang juga sangat tinggi (0,99). Artinya, kesalahan dalam mengklasifikasikan data sangat minim, menjadikan model ini sangat andal untuk prediksi penyakit jantung.



*Gambar 2. Confusion matrix algoritma Decision Tree*

Berdasarkan Gambar 2, model Decision Tree menunjukkan performa klasifikasi yang sangat baik. Dari total 205 data, model berhasil mengklasifikasikan seluruh 102 data pada kelas 0 (tidak terkena penyakit jantung) dengan benar tanpa kesalahan. Sementara itu, pada kelas 1 (terkena penyakit jantung), sebanyak 100 data berhasil diklasifikasikan dengan benar, dan hanya 3 data yang salah diklasifikasikan sebagai tidak terkena penyakit jantung.


#### D. Klasifikasi dengan Algoritma Random Forest

Pada tahap ini, dilakukan proses klasifikasi menggunakan algoritma Random Forest untuk memprediksi kemungkinan seseorang terkena penyakit jantung. Evaluasi performa model dilakukan dengan menggunakan metrik-metrik evaluasi seperti precision, recall, dan F1-score.

*Tabel 7. Evaluasi model Random Forest*

|              | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0            | 0,97      | 1,00   | 0,99     | 102     |
| 1            | 1,00      | 0,97   | 0,99     | 103     |
| Accuracy     |           |        | 0,99     | 205     |
| Macro avg    | 0,99      | 0,99   | 0,99     | 205     |
| Weighted avg | 0,99      | 0,99   | 0,99     | 205     |

Hasil evaluasi kinerja model pada Tabel 7 terhadap dua kelas, yaitu kelas 0 (tidak terkena penyakit jantung) dan kelas 1 (terkena penyakit jantung), ditampilkan dalam bentuk metrik evaluasi berikut: precision, recall, F1-score, dan support. Berdasarkan hasil pada tabel, model memiliki akurasi sebesar 0,99, precision 1,00 untuk kelas positif, recall 0,97, dan F1-score 0,99.



*Gambar 3. Confusion matrix algoritma Random Forest*

Berdasarkan Gambar 3, model Random Forest menunjukkan performa klasifikasi yang sangat baik. Dari total 205 data, seluruh 102 data pada kelas 0 (tidak terkena penyakit jantung) berhasil diklasifikasikan dengan benar. Pada kelas 1 (terkena penyakit jantung), sebanyak 100 data diklasifikasikan dengan benar, dan hanya 3 data yang salah diklasifikasikan sebagai tidak terkena penyakit jantung.

#### E. Klasifikasi dengan Algoritma K-Nearest Neighbors


Pada tahap ini, dilakukan proses klasifikasi menggunakan algoritma K-Nearest Neighbors untuk memprediksi kemungkinan seseorang terkena penyakit jantung. Evaluasi performa model dilakukan dengan menggunakan metrik-metrik evaluasi seperti precision, recall, dan F1-score.

Hasil evaluasi kinerja model pada Tabel 8 terhadap dua kelas, yaitu kelas 0 (tidak terkena penyakit jantung) dan kelas 1 (terkena penyakit jantung), ditampilkan dalam bentuk metrik evaluasi: precision, recall, F1-score, dan

support. Berdasarkan hasil evaluasi, model mencapai akurasi sebesar 0,84, dengan nilai precision dan recall yang seimbang di kedua kelas.

Tabel 8. Evaluasi model K-Nearest Neighbors

|              | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0            | 0,85      | 0,83   | 0,84     | 102     |
| 1            | 0,84      | 0,85   | 0,84     | 103     |
| Accuracy     |           |        | 0,84     | 205     |
| Macro avg    | 0,84      | 0,84   | 0,84     | 205     |
| Weighted avg | 0,84      | 0,84   | 0,84     | 205     |



Gambar 4. Confusion matrix algoritma KNN

Berdasarkan Gambar 4, model K-Nearest Neighbors menunjukkan performa yang cukup baik, meskipun tidak seakurat model sebelumnya. Dari total 205 data, model berhasil mengklasifikasikan 85 data kelas 0 (tidak terkena penyakit jantung) dengan benar, namun 17 data salah diklasifikasikan sebagai kelas 1. Untuk kelas 1 (terkena penyakit jantung), sebanyak 88 data diklasifikasikan dengan benar, dan 15 data salah diklasifikasikan sebagai kelas 0.

#### F. Klasifikasi dengan Algoritma Support Vector Machine


Pada tahap ini, dilakukan proses klasifikasi menggunakan algoritma Support Vector Machine untuk memprediksi kemungkinan seseorang terkena penyakit jantung. Evaluasi performa model dilakukan dengan menggunakan metrik-metrik evaluasi seperti precision, recall, dan F1-score.

Tabel 9. Evaluasi model Support Vector Machine

|              | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| 0            | 0,91      | 0,84   | 0,87     | 102     |
| 1            | 0,85      | 0,91   | 0,88     | 103     |
| Accuracy     |           |        | 0,88     | 205     |
| Macro avg    | 0,88      | 0,88   | 0,88     | 205     |
| Weighted avg | 0,88      | 0,88   | 0,88     | 205     |

Hasil evaluasi kinerja model pada Tabel 9 terhadap dua kelas, yaitu kelas 0 (tidak terkena penyakit jantung) dan kelas 1 (terkena penyakit jantung), ditunjukkan melalui metrik evaluasi seperti precision, recall, F1-score, serta jumlah data pada masing-masing kelas (support). Model ini mencapai akurasi sebesar 0,88, dengan nilai precision dan recall yang saling melengkapi di kedua kelas.

Berdasarkan Gambar 5, model Support Vector Machine menunjukkan performa yang sangat baik dalam mengklasifikasikan data. Dari total 205 data, model berhasil mengklasifikasikan 86 data kelas 0 (tidak terkena penyakit jantung) dengan benar dan salah mengklasifikasikan 16 data sebagai kelas 1. Sementara itu, untuk kelas 1 (terkena penyakit jantung), sebanyak 94 data diklasifikasikan dengan benar dan hanya 9 data yang salah diklasifikasikan sebagai kelas 0.



Gambar 5. Confusion matrix algoritma Support Vector Machine

#### G. Analisis Perbandingan Algoritma Klasifikasi

Berikut adalah hasil evaluasi performa empat algoritma menggunakan metode 5-Fold Cross-Validation. Tabel berikut menunjukkan nilai akurasi dan variasi performa pada setiap model untuk mengukur konsistensi dan kemampuan generalisasi mereka.

Tabel 10. Cross validation terhadap empat algoritma

| Model         | Fold Scores                              | Mean Accuracy | Std Dev ( $\pm$ ) |
|---------------|------------------------------------------|---------------|-------------------|
| Decision Tree | [1.0000, 0.9756, 0.9634, 0.9817, 0.9878] | 0.9817        | 0.0161            |
| Random Forest | [1.0000, 0.9634, 0.9634, 0.9939, 0.9878] | 0.9817        | 0.0179            |
| KNN           | [0.8232, 0.8293, 0.8232, 0.8780, 0.8963] | 0.8500        | 0.0319            |
| SVM           | [0.9085, 0.9024, 0.8598, 0.8841, 0.9085] | 0.8927        | 0.0159            |

Hasil evaluasi menggunakan 5-Fold Cross-Validation yang ditampilkan pada Tabel IX menunjukkan bahwa semua model yang diuji yaitu Decision Tree, Random Forest, K-Nearest Neighbors (KNN), dan Support Vector Machine (SVM) memiliki performa yang konsisten di seluruh fold. Model Decision Tree dan Random Forest mencatat rata-rata akurasi sebesar 98,17% dengan standar deviasi masing-masing sebesar  $\pm 0.0161$  dan  $\pm 0.0179$ , menandakan kestabilan performa antar lipatan. Sementara itu, model KNN dan SVM mencatat rata-rata akurasi masing-masing sebesar 85,00% dan 89,27%, dengan variasi antar fold yang juga tetap dalam batas wajar.

Berdasarkan hasil tersebut, dapat disimpulkan bahwa tidak terdapat indikasi overfitting pada keempat model, karena seluruhnya menunjukkan performa yang stabil dan tidak hanya unggul pada sebagian fold saja. Skor yang konsisten serta standar deviasi yang rendah menunjukkan bahwa masing-masing model memiliki kemampuan generalisasi yang baik terhadap data yang belum pernah dilihat sebelumnya. Hal ini penting untuk memastikan bahwa model tidak hanya bekerja baik pada data pelatihan, tetapi juga dapat diandalkan dalam penerapan di dunia nyata.

#### H. Evaluasi menggunakan Cross Validation

Untuk memahami performa dari keempat algoritma klasifikasi yang digunakan dalam prediksi penyakit jantung yaitu Decision Tree, Random Forest, K-Nearest Neighbors (KNN), dan Support Vector Machine (SVM) dilakukan evaluasi menggunakan metrik utama klasifikasi yaitu akurasi, presisi, recall, dan F1-score. Metrik-metrik ini memberikan gambaran menyeluruh mengenai


kemampuan model dalam memprediksi dua kelas utama: penderita dan bukan penderita penyakit jantung.

Tabel 11. Perbandingan evaluasi model

| Model         | Akurasi | Presisi (Kelas 1) | Recall (Kelas 1) | F1-score (Kelas 1) |
|---------------|---------|-------------------|------------------|--------------------|
| Decision Tree | 0,99    | 1,00              | 0,97             | 0,99               |
| Random Forest | 0,99    | 1,00              | 0,97             | 0,99               |
| KNN           | 0,84    | 0,84              | 0,85             | 0,85               |
| SVM           | 0,88    | 0,85              | 0,91             | 0,88               |

Berdasarkan hasil evaluasi pada Tabel 11, algoritma Decision Tree dan Random Forest menunjukkan performa terbaik dengan akurasi sebesar 99%, presisi sempurna (1.00) untuk kelas positif, recall tinggi (0.97), dan F1-score yang sangat baik (0.99), menandakan efektivitas tinggi dalam mendeteksi pasien berisiko tanpa banyak kesalahan klasifikasi. Sebaliknya, model K-Nearest Neighbors (KNN) memiliki performa paling rendah dengan akurasi 84% serta precision dan recall sekitar 0.85, menunjukkan kecenderungan menghasilkan lebih banyak kesalahan klasifikasi yang kemungkinan dipengaruhi oleh sensitivitas terhadap parameter dan skala data. Sementara itu, Support Vector Machine (SVM) berada di tingkat menengah dengan akurasi 88%, precision 0.85, recall 0.91, dan F1-score 0.88, mencerminkan kemampuannya yang baik dalam menangkap kasus positif meskipun dengan sedikit peningkatan risiko false positives.

Grafik pada Gambar 6 menunjukkan perbandingan nilai metrik evaluasi untuk setiap model klasifikasi. Terlihat jelas bahwa Decision Tree dan Random Forest mendominasi di keempat metrik, dengan skor yang mendekati nilai sempurna. Sementara itu, KNN memiliki kinerja paling rendah dan tidak menunjukkan keunggulan signifikan pada salah satu metrik. Model SVM memiliki keseimbangan yang baik antara recall dan F1-score, meskipun precision-nya tidak setinggi dua model teratas.



Gambar 6. Perbandingan metrik kinerja algoritma klasifikasi

## IV. KESIMPULAN

Berdasarkan hasil evaluasi empat algoritma klasifikasi yaitu Decision Tree, Random Forest, K-Nearest Neighbors (KNN), dan Support Vector Machine (SVM) dapat disimpulkan bahwa Decision Tree dan Random Forest memberikan performa terbaik dalam memprediksi penyakit jantung dengan akurasi 99%, precision sempurna (1.00), serta recall dan F1-score tinggi (0.97 dan 0.99). Evaluasi 5-Fold Cross-Validation juga menunjukkan

stabilitas dan kemampuan generalisasi yang baik tanpa indikasi overfitting. Sementara itu, KNN memiliki performa terendah (84%), dan SVM sedikit lebih baik dengan akurasi 88% serta recall tinggi (0.91).

Secara keseluruhan, Decision Tree dan Random Forest direkomendasikan sebagai model paling andal. Namun, untuk meningkatkan hasil di penelitian selanjutnya, disarankan agar dataset diperbanyak dan lebih beragam, serta dilakukan optimalisasi model melalui hyperparameter tuning agar performa prediksi semakin akurat dan andal.

## DAFTAR PUSTAKA

- [1] N. Adhyka, E. T. Effandilus, and A. Y. Putri, "Faktor risiko kejadian penyakit jantung koroner di poliklinik RSUD Solok Selatan tahun 2022," *Jurnal Pembangunan Nagari*, vol. 8, no. 1, 2023, doi: 10.30559/jpn.v8i1.392.
- [2] E. M. Marwali, Y. Purnama, and P. S. Roebiono, "Modalities for Early Detection of Congenital Heart Disease in Primary Health Services", *J. Indones. Med. Assoc.*, vol. 71, no. 2, pp. 100–109, Apr.–May 2021, doi: 10.47830/jinma-vol.71.2-2021-241.
- [3] Y. Amelia, "Perbandingan metode machine learning untuk mendeteksi penyakit jantung," *Idealis: Indonesia Journal of Information System*, vol. 6, no. 2, pp. 220–225, 2023, doi: 10.36080/idealis.v6i2.3043.
- [4] B. Wibisono and A. Fahrurrozi, "Perbandingan algoritma klasifikasi dalam pengklasifikasian data penyakit jantung koroner," *Jurnal Ilmiah Teknologi dan Rekayasa*, vol. 24, no. 3, pp. 161–170, 2019, doi: 10.35760/tr.2019.v24i3.2393.
- [5] M. F. Costantino, F. Cortese, G. D'Addeo, A. Nicoletti, S. Mancino, and L. Stolfi, "Diagnostic modalities for ischemic heart disease: Evaluating the role of stress echocardiography, cardiac CT, and myocardial perfusion scintigraphy in guiding coronary angiography," *Exploration of Cardiology*, Jan. 2025, doi: 10.37349/ec.2025.101243.
- [6] T. K. Ningsih and H. Zakaria, "Implementasi algoritma k-nearest neighbor pada sistem deteksi penyakit jantung (studi kasus: Klinik Makmur Jaya)," *Jurnal Ilmu Komputer dan Pendidikan*, vol. 2, no. 1, pp. 6–21, 2023. [Online]. Available: <https://journal.mediapublikasi.id/index.php/logic/article/view/2448>
- [7] P. Peace, J. Chris, and L. Victor, "Data preprocessing for AI models," 2024. [Online]. Available: <https://www.researchgate.net/publication/385707249>
- [8] H. Priatmojo, F. Saputra, M. H. Prasetyo, D. Puspitasari, and D. Nurlaela, "Perbandingan klasifikasi tingkat penjualan buah di supermarket dengan pendekatan algoritma decision tree, naive Bayes dan k-nearest neighbor," *Jurnal INSAN (Journal of Information Systems Management Innovation)*, vol. 3, no. 1, 2023, doi: 10.31294/jinsan.v3i1.2097.
- [9] P. Rim and E. Liu, "Optimizing the C4.5 decision tree algorithm using MSD-splitting," *IJACSA (International Journal of Advanced Computer Science and Applications)*, vol. 11, no. 10, 2020, doi: 10.14569/IJACSA.2020.0111006.
- [10] C. N. Syahputri and M. S. Hasibuan, "Optimasi klasifikasi decision tree dengan teknik pruning untuk mengurangi overfitting," *JSil (Jurnal Sistem Informasi)*, vol. 11, no. 2, pp. 87–96, Sep. 2024, doi: 10.30656/jsii.v11i2.9161.
- [11] P. Argadianata, D. A. Fatah, H. Sukri, J. R. Telang, K. Kamal, and J. Timur, "Klasifikasi kualitas buah apel menggunakan metode random forest," *Jurnal Mahasiswa Teknik Informatika*, vol. 9, no. 2, 2025, doi: 10.36040/jati.v9i2.12854.
- [12] M. A. Hassan, H. Salem, N. Bailek, and O. Kisi, "Random forest ensemble-based predictions of on-road vehicular emissions and fuel consumption in developing urban areas," *Sustainability (Switzerland)*, vol. 15, no. 2, Jan. 2023, doi: 10.3390/su15021503.
- [13] M. Haddouchi and A. Berrado, "A survey and taxonomy of methods interpreting random forest models conflict of interest," 2024, doi: 10.48550/arXiv.2407.12759.
- [14] Yogianto, A. Homaidi, and Z. Fatah, "Implementasi metode k-nearest neighbors (KNN) untuk klasifikasi penyakit jantung," *G-*

Tech: Jurnal Teknologi Terapan, vol. 8, no. 3, pp. 1720–1728, Jul. 2024, doi: 10.33379/gtech.v8i3.4495.

- [15] M. H. Setiono, "Komparasi algoritma decision tree, random forest, SVM dan K-NN dalam klasifikasi kepuasan penumpang maskapai penerbangan," *INTI Nusa Mandiri*, vol. 17, no. 1, pp. 32–39, Oct. 2022, doi: 10.33480/inti.v17i1.3420.
- [16] A. Amer, S. D. Ravana, and R. A. A. Habeeb, "Effective k-nearest neighbor models for data classification enhancement," *Journal of Big Data*, vol. 12, no. 1, Dec. 2025, doi: 10.1186/s40537-025-01137-2.
- [17] Mulyani, S. Khoerunisa, and D. Kurniadi, "Perbandingan kinerja algoritma KNN dan SVM menggunakan SMOTE untuk klasifikasi penyakit diabetes," *Jurnal Nasional Teknik Elektro dan Teknologi Informasi*, vol. 14, no. 1, pp. 25–34, Feb. 2025, doi: 10.22146/jnteti.v14i1.15198.
- [18] Z. Jun, "The development and application of support vector machine," *J. Phys. Conf. Ser.*, vol. 1748, no. 5, Jan. 2021, doi: 10.1088/1742-6596/1748/5/052006.
- [19] S. Adaramaja, S. Aliyu, and F. B. Abdullahi, "Hyper-parameter tuning for support vector machine using an improved cat swarm optimization algorithm," *Journal of the Nigerian Society of Physical Sciences*, vol. 5, no. 4, Nov. 2023, doi: 10.46481/jnsps.2023.1007.
- [20] F. AlShammari, "Implementation of model evaluation using confusion matrix in Python," *International Journal of Computer Applications*, vol. 186, no. 50, pp. 42–48, Nov. 2024, doi: 10.5120/ijca2024924236.
- [21] O. Wilson, D. Schoeman, A. Bradley, and C. Clemente, "Practical guidelines for validation of supervised machine learning models in accelerometer-based animal behaviour classification," *Journal of Animal Ecology*, May 2025, doi: 10.1111/1365-2656.70054.
- [22] L. A. Yates, Z. Aandahl, S. A. Richards, and B. W. Brook, "Cross validation for model selection: A review with examples from ecology," *Ecol. Monogr.*, vol. 93, no. 1, Feb. 2023, doi: 10.1002/ecm.1557.