

Komparasi Performansi Model Machine Learning untuk Prediksi Readmisi Pasien Gagal Jantung

Fatimah Aznur ^{#1}, Paizal Merdijaya ^{#2}, Qisthi Alhazmi Hidayaturohman ^{*3}

*# Informatics Engineering Department, Sekolah Tinggi Teknologi Terpadu Nurul Fikri
Depok, Jawa Barat, Indonesia*

¹ fati21183ti@student.nurulfikri.ac.id

² paiz21014ti@student.nurulfikri.ac.id

**Faculty of Engineering, Universitas Pembangunan Nasional Veteran Jakarta
Depok, Jawa Barat, Indonesia*

³ qisthialhazmi@upnvj.ac.id

Received on 31-05-2025, revised 06-06-2025, accepted on 27-06-2025

Abstract

Cardiovascular diseases are the leading cause of global mortality. By utilizing machine learning methods, patient data analysis can estimate risk and plan more effective interventions. The aim of this study is to evaluate the performance of algorithms such as Random Forest, Decision Tree, and Gradient Boosting in predicting cardiovascular diseases. The first step involves using the K-Nearest Neighbors (KNN) imputation method to address missing values in the dataset derived from cardiovascular disease patients. The data is split into training and testing sets with a ratio of 80:20. The three machine learning algorithms are tested on this data, with evaluations conducted using accuracy, precision, recall, and F1-score. The results show that Random Forest delivers the best performance with an accuracy of 65%, precision of 60%, recall of 31%, and F1-score of 41%. Although Decision Tree and Gradient Boosting demonstrate competitive results, they are slightly lower than those of Random Forest. The KNN imputation method is proven effective in handling missing values. In conclusion, Random Forest outperforms, followed by Gradient Boosting and Decision Tree, providing a foundation for the development of more accurate predictive models in diagnosing cardiovascular diseases.

Keywords: heart failure, machine learning, KNN imputation, Random Forest, Decision Tree, Gradient Boosting.

I. PENDAHULUAN

Penyakit jantung merupakan ancaman serius bagi kesehatan global, menyebabkan tingginya angka kematian di seluruh dunia [1]. Pengelolaan dan prediksi risiko penyakit jantung adalah aspek krusial dalam upaya pencegahan dan penanganan dini [2]. Meskipun telah banyak metode untuk menganalisis data pasien penyakit jantung, masih ada tantangan dalam memprediksi risiko secara akurat dan merumuskan strategi penanganan yang efektif. Salah satu masalah utamanya adalah adanya nilai yang hilang dalam data, yang dapat memengaruhi keakuratan analisis dan prediksi [3]. Penelitian ini bertujuan untuk mengevaluasi kinerja beberapa algoritma machine learning, seperti Random Forest, Decision Tree, dan Gradient Boosting, dalam memprediksi penyakit jantung setelah menerapkan metode imputasi berbasis K-Nearest Neighbors (KNN) untuk menangani nilai yang hilang. Hasil penelitian ini diharapkan dapat memberikan pemahaman yang lebih dalam tentang kinerja berbagai algoritma machine learning dalam konteks prediksi penyakit jantung. Selain itu, penerapan

metode imputasi KNN juga diharapkan dapat memberikan kontribusi dalam penanganan data yang tidak lengkap dalam studi-studi lainnya di bidang kesehatan.

II. METODE PENELITIAN

A. Dataset

Untuk mengembangkan model prediksi yang dapat membantu diagnosis penyakit jantung, kami menggunakan dataset pasien yang tersedia di PhysioNet [4], sebuah platform data yang terkenal di kalangan peneliti dan praktisi data medis. Dataset ini menyediakan informasi komprehensif yang meliputi data medis dan demografis dari 2.009 pasien dengan berbagai kondisi kesehatan jantung. Dataset ini memiliki 167 variabel yang mencakup berbagai aspek seperti informasi umum pasien, detail penerimaan dan pemulangan, data klinis, hasil laboratorium dan tes medis, serta informasi tambahan dari laboratorium dan tes medis. Variabel-variabel ini terdiri dari berbagai jenis data, termasuk tipe objek untuk informasi kategoris, desimal untuk hasil tes medis, dan bilangan bulat untuk variabel seperti usia. Seluruh data disusun dalam format tabel, yang memudahkan proses analisis dan pemrosesan lebih lanjut.

B. Data Pre-processing

Dalam pengembangan model algoritma machine learning, persiapan data atau pre-processing menjadi tahap kritis, terutama ketika data mengandung nilai yang hilang atau missing value. Pada dataset yang digunakan untuk penelitian ini, ditemukan bahwa sejumlah variabel memiliki nilai missing value dalam jumlah yang signifikan, di mana beberapa variabel memiliki lebih dari 50% nilai yang hilang, sementara yang lain memiliki kurang dari 50%. Untuk menangani nilai-nilai missing value, pendekatan yang diambil berdasarkan persentase nilai yang hilang. Variabel yang memiliki lebih dari 50% nilai yang hilang dianggap kurang informatif dan dihapus dari analisis, karena potensi informasi yang terbatas yang dapat mereka berikan [5]. Sedangkan, untuk variabel yang memiliki kurang dari 50% nilai yang hilang, metode imputasi digunakan untuk mengisi nilai yang hilang. Imputasi dilakukan menggunakan metode Teknik Imputasi berbasis KNN, yang merupakan salah satu teknik yang umum digunakan dalam machine learning untuk menangani missing value. Namun, penting untuk mencatat bahwa sumber imputasi yang digunakan tidak hanya berasal dari satu sumber, tetapi dari beberapa sumber yang berbeda. Hal ini dilakukan untuk memastikan ketepatan dan validitas hasil imputasi.

Teknik K-Nearest Neighbor (KNN) digunakan dalam informasi statistik, terdiri dari kumpulan label tetangga yang dimanfaatkan untuk menentukan label pada setiap contoh uji dengan memanfaatkan sebuah prinsip yaitu Maximum A Posteriori (MAP). Proses ini mencakup identifikasi tetangga terdekat dari setiap contoh uji dalam set data latihan [6]. Untuk mengatasi kekosongan data dalam dataset, kami menggunakan teknik imputasi KNNImputer dari pustaka scikit-learn [7]. Dengan metode ini, kami mengisi nilai yang kosong dengan estimasi yang dihitung berdasarkan nilai dari tetangga terdekat dalam ruang fitur.

C. Pembangunan Model

Dalam penelitian ini, data yang telah melalui tahap pra-pemrosesan, termasuk imputasi nilai yang hilang, diproses lebih lanjut untuk pengembangan model prediktif. Model ini dibangun menggunakan beberapa algoritma, yaitu *Random Forest*, *Decision Tree*, dan *eXtreme Gradient Boosting* (XGBoost).

Pengklasifikasi Hutan Acak (*Random Forest*/RF) merupakan salah satu metode ansambel dalam machine learning untuk membangun banyak pohon keputusan yang diambil dari subset sampel dan variabel pelatihan yang dilakukan pemilihan secara acak. Teknik ini sangat populer karena keunggulannya dalam hal akurasi klasifikasi. *Random Forest* efektif dalam mengatasi dataset dengan banyak variabel, mengatasi multikolinearitas, bekerja dengan cepat, dan tidak mudah mengalami overfitting. Namun, sensitivitas terhadap pemilihan sampel pelatihan tetap menjadi tantangan bagi *Random Forest* [8].

Metode pohon keputusan (*Decision Trees*) seringkali digunakan dalam data mining untuk menciptakan sistem klasifikasi yang didasarkan pada berbagai kovariat atau untuk mengembangkan algoritma prediksi bagi variabel

target. Teknik ini melakukan pengelompokan populasi ke dalam beberapa segmen yang digambarkan sebagai bentuk cabang-cabang dari pohon terbalik, terdiri dari beberapa simpul seperti simpul akar, simpul internal, dan simpul daun. Algoritma ini bersifat non-parametrik serta mampu melakukan pengelolaan kumpulan data-data dengan kapasitas yang besar dan kompleks tanpa harus membutuhkan struktur parametrik yang rumit [9].

Gradient Boosting merupakan sebuah teknik dalam pembelajaran mesin yang tergolong canggih dan telah terbukti terkait keberhasilannya dalam aplikasi praktis yang beragam. Metode ini tergolong fleksibel dan dapat menyesuaikan kebutuhan tertentu pada aplikasi, terutama pada keterkaitannya dengan fungsi kerugian yang beragam [10].

D. Evaluasi Model

Model yang telah dibangun dievaluasi menggunakan parameter seperti akurasi, presisi, nilai F1, recall, dan nilai area di bawah kurva (AUC-ROC). Akurasi pada model menentukan nilai performa model dalam memprediksi hasil dengan baik sedangkan presisi ketepatan model dalam memprediksi hasil positif. Recall menunjukkan performa model dalam menentukan nilai kasus positif yang dihasilkan dari prediksi model. Nilai F1 merupakan gabungan dari nilai presisi dan recall. Terakhir adalah, AUC-ROC yang menentukan performa hasil klasifikasi dari model yang dibangun [11]. Parameter-parameter tersebut dapat menentukan apakah model yang dibangun memiliki performa yang baik atau tidak dalam memprediksi readmisi pada pasien.

III. HASIL DAN DISKUSI

A. Model Random Forest

Pada evaluasi kinerja algoritma Random Forest terhadap dataset yang digunakan. Hasil evaluasi menunjukkan bahwa model memiliki tingkat akurasi sebesar 65%, yang mencerminkan kemampuan model untuk memprediksi dengan benar secara keseluruhan. Selain itu, precision sebesar 60% menunjukkan proporsi prediksi positif yang benar dari keseluruhan prediksi yang dilakukan. ROC-AUC sebesar 0.63 menunjukkan kemampuan model untuk membedakan antara kelas positif dan negatif. Lebih lanjut, F1 Score sebesar 0.41 mencerminkan keseimbangan antara precision dan recall, dengan recall sebesar 31% menunjukkan proporsi kelas positif yang berhasil diidentifikasi dari keseluruhan kelas positif yang ada.


TABEL 1
HASIL PERFORMA MODEL RANDOM FOREST

Accuracy	Precision	ROC-AUC	F1-Score	Recall
0.65	0.60	0.63	0.41	0.31

Laporan klasifikasi yang dihasilkan oleh algoritma Random Forest menyajikan evaluasi komprehensif dari kinerja model untuk setiap kelas dan rata-rata keseluruhan. Untuk kelas 0, presisi adalah 0,66 dan recall adalah 0,87, menghasilkan F1 Score sebesar 0,75, menunjukkan keseimbangan antara presisi dan recall. Di sisi lain, untuk kelas 1, presisi adalah 0,60, recall adalah 0,31, dan F1 Score adalah 0,41. Metrik-metrik ini memberikan wawasan tentang kemampuan model Random Forest dalam mengklasifikasikan data secara akurat untuk masing-masing kelas dan secara keseluruhan.

TABEL 2
HASIL CLASSIFICATION REPORT MODEL RANDOM FOREST

	Precision	Recall	F1-Score
Class 0	0.66	0.87	0.75
Class 1	0.60	0.31	0.41
Macro Avg	0.63	0.59	0.58
Weigthed Avg	0.64	0.65	0.62



Gambar 1. Grafik Kurva ROC Model Random Forest

B. Model Decision Tree

Dari evaluasi model algoritma Decision Tree, ditemukan tingkat akurasi sebesar 56%, yang mencerminkan kemampuan model dalam memprediksi secara tepat secara keseluruhan. Precision sebesar 45% menunjukkan proporsi prediksi positif yang benar dari semua prediksi positif yang dilakukan. ROC-AUC sebesar 0.55 mengindikasikan kemampuan model dalam membedakan antara kelas positif dan negatif. Selanjutnya, F1 Score sebesar 0.45 menunjukkan keseimbangan antara precision dan recall, sementara recall sebesar 46% menggambarkan proporsi kelas positif yang berhasil diidentifikasi dari keseluruhan kelas positif yang ada. Hasil evaluasi ini memberikan pemahaman yang cukup komprehensif tentang kinerja algoritma Decision Tree dalam melakukan prediksi kelas target.


TABEL 3
 HASIL PERFORMA MODEL DECISION TREE

Accuracy	Precision	ROC-AUC	F1-Score	Recall
0.56	0.45	0.55	0.45	0.46

Hasil laporan klasifikasi dari model algoritma Decision Trees mencerminkan evaluasi kinerja untuk setiap kelas serta rata-rata keseluruhan. Untuk kelas 0, precision 0.64 menunjukkan akurasi prediksi positif, dengan recall 0.63 menggambarkan proporsi positif yang teridentifikasi. F1 Score mencapai 0.64, menunjukkan keseimbangan antara precision dan recall. Untuk kelas 1, precision adalah 0.45, recall adalah 0.46, dan F1 Score adalah 0.45. Nilai rata-rata dari precision, recall, dan F1 Score ditunjukkan oleh nilai macro avg dan weighted avg, memberikan gambaran komprehensif tentang kinerja model Decision Trees dalam mengklasifikasikan data untuk setiap kelas dan secara keseluruhan.

TABEL 4
 HASIL CLASSIFICATION REPORT MODEL DECISION TREE

	Precision	Recall	F1-Score
Class 0	0.64	0.63	0.64
Class 1	0.45	0.46	0.45
Macro Avg	0.55	0.55	0.55
Weighed Avg	0.57	0.56	0.57



Gambar 2. Grafik Kurva ROC Model Decision Tree

C. Model Gradient Boosting

Hasil evaluasi matriks dari model algoritma Gradient Boosting menunjukkan kinerja model secara komprehensif. Dengan tingkat akurasi sebesar 60%, model mampu memprediksi dengan benar sebagian besar data uji. Precision sebesar 58% menunjukkan bahwa sebagian besar dari prediksi positif model adalah benar. ROC-AUC sebesar 0.63 menunjukkan kemampuan model untuk membedakan antara kelas positif dan negatif dengan baik. F1 Score sebesar 0.58 menunjukkan keseimbangan antara presisi dan recall, sedangkan recall sebesar 60% mengindikasikan bahwa sebagian besar dari kelas positif berhasil diidentifikasi. Dengan demikian, hasil evaluasi ini menyiratkan bahwa model Gradient Boosting mampu memberikan prediksi yang handal terhadap kelas target.


TABEL 5
 HASIL PERFORMA MODEL GRADIENT BOOSTING

Accuracy	Precision	ROC-AUC	F1-Score	Recall
0.60	0.58	0.63	0.58	0.60

Laporan klasifikasi dari model algoritma Gradient Boosting memberikan evaluasi kinerja untuk setiap kelas dan nilai rata-rata dari keseluruhan kelas. Presisi, recall, dan F1 Score untuk kelas 0 secara signifikan lebih tinggi daripada kelas 1, menunjukkan kemampuan model dalam memprediksi dengan lebih baik untuk mayoritas kelas. Nilai rata-rata dari semua kelas diperlihatkan oleh nilai rata-rata mikro (micro avg) dan rata-rata tertimbang (weighted avg), dengan nilai tertimbang memberikan penekanan berdasarkan jumlah contoh dalam setiap kelas. Hasil ini memberikan gambaran yang komprehensif tentang kinerja model dalam mengklasifikasikan data.

TABEL 6
 HASIL CLASSIFICATION REPORT MODEL GRADIENT BOOSTING

	Precision	Recall	F1-Score
Class 0	0.64	0.80	0.71
Class 1	0.49	0.31	0.38
Macro Avg	0.57	0.55	0.55
Weigthed Avg	0.58	0.60	0.58



Gambar 3. Grafik Kurva ROC Model Gradient Boosting

D. Diskusi

Dalam ini, metode imputasi berbasis K-Nearest Neighbors (KNN) diterapkan, diikuti dengan penggunaan model algoritma Random Forest, Decision Trees, dan Gradient Boosting untuk klasifikasi data. Evaluasi performa model dilakukan menggunakan metrik-metrik seperti akurasi, precision, recall, F1 score, dan ROC-AUC.

Hasil evaluasi menunjukkan bahwa model Random Forest memiliki performa terbaik dengan akurasi 0.65 dan ROC-AUC 0.63. Precision dan recall untuk kelas mayoritas (kelas 0) sangat tinggi (0.66 dan 0.87), menunjukkan kemampuan model dalam memprediksi kelas mayoritas dengan baik. Namun, recall untuk kelas minoritas (kelas 1) lebih rendah (0.31), menunjukkan bahwa model ini kurang efektif dalam menangkap semua kasus positif di kelas minoritas. Menurut Breiman (2001), Random Forest mengombinasikan hasil dari banyak pohon keputusan, mengurangi varians tanpa meningkatkan bias secara signifikan, dan tahan terhadap overfitting, terutama pada dataset yang besar dan kompleks [12].

Performa model akurasi sebesar 0.56 dan ROC-AUC sebesar 0.55. Meskipun presisi dan recall untuk kelas mayoritas cukup baik, nilai presisi dan recall untuk kelas minoritas hanya mencapai 0.45 dan 0.46 secara berturut-turut. Hal ini menunjukkan bahwa model memiliki keterbatasan dalam mengklasifikasikan data, terutama untuk kelas minoritas. Menurut Quinlan (1986), Decision Trees adalah model yang mudah diinterpretasikan dan sederhana. Namun, model ini cenderung mengalami overfitting pada dataset yang memiliki banyak fitur dan kompleksitas tinggi [13]. Oleh karena itu, perlu dilakukan penyesuaian atau peningkatan pada model untuk meningkatkan kemampuannya dalam mengatasi masalah klasifikasi, terutama pada data yang memiliki ketidak seimbangan kelas.

Model Gradient Boosting menunjukkan performa yang cukup baik dengan akurasi sebesar 0.60 dan ROC-AUC sebesar 0.63, Gradient Boosting secara konsisten mencapai hasil yang setara dengan metode Random Forest. Meskipun precision dan recall untuk kelas mayoritas sedikit lebih rendah daripada Random Forest, hasilnya masih mencerminkan keseimbangan yang memadai. Namun demikian, mirip dengan Random Forest, Gradient Boosting juga menemui tantangan dalam memprediksi kelas minoritas (kelas 1), dengan precision sebesar 0.49 dan recall sebesar 0.31. Sebagaimana dijelaskan oleh Friedman (2001), algoritma Gradient Boosting secara iteratif mengurangi bias dengan membangun model berdasarkan sisa prediksi sebelumnya [14].

Pendekatan ini membuktikan keefektifannya dalam menangani data yang tidak seimbang dan kompleks, meskipun memerlukan komputasi yang lebih intensif.

IV. KESIMPULAN

Dalam penelitian ini, kami menganalisis kinerja tiga model berbeda untuk tujuan klasifikasi data menggunakan model Random Forest, Gradient Boosting, dan Decision Trees. Berdasarkan hasil evaluasi, Random Forest menunjukkan keunggulan sebagai model dengan kinerja terbaik dan menunjukkan hasil yang sangat baik dalam berbagai metrik evaluasi. Akurasi keseluruhan yang tinggi menandakan kemampuannya untuk memprediksi dengan tepat, sementara ketidakkenderungan untuk overfitting menjadikannya pilihan yang solid untuk kasus dataset yang kompleks. Di sisi lain, Decision Trees menunjukkan performa terendah di antara ketiga model yang diuji. Kelemahan utamanya terletak pada kemampuannya yang terbatas dalam mengklasifikasikan dengan benar, terutama untuk kelas minoritas, yang mengindikasikan bahwa model ini kurang cocok untuk dataset yang kompleks. Meskipun Gradient Boosting menunjukkan hasil yang kompetitif, terutama dalam hal akurasi, model ini tidak mampu menyaingi Random Forest dalam hal kemampuan menangkap variasi dalam data tanpa overfitting. Oleh karena itu, Random Forest menjadi pilihan yang lebih unggul untuk klasifikasi dalam konteks penelitian ini.

Berdasarkan analisis kinerja yang teliti, kami memilih Random Forest sebagai model terbaik untuk klasifikasi dalam konteks penelitian ini. Keputusan ini didukung oleh teori yang menggarisbawahi kemampuan Random Forest dalam menangani dataset besar dan kompleks secara efektif, sambil tetap mempertahankan tingkat akurasi yang tinggi.

ACKNOWLEDGMENT

Penulis ingin berterima kasih kepada STT Terpadu Nurul Fikri yang telah memberikan dukungan kepada penulis dalam lancarnya melaksanakan studi ini.

REFERENCES

- [1] Health Organization, 2021. "Cardiovascular diseases (CVDs)." World Health Organization. Available: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [2] A. Rout, S. Duhan, M. Umer, M. Li, and D. Kalra, 2023. "Atherosclerotic cardiovascular disease risk prediction: current state-of-the-art." *Heart*. Available: <https://doi.org/10.1136/heartjnl-2023-322928>.
- [3] N. A. Baghdadi, S. Mohammed, A. Malki, I. Gad, A. A. Ewis, and El-Sayed Atlam, 2023. "Advanced machine learning techniques for cardiovascular disease early detection and diagnosis." *Journal of Big Data*, vol. 10, no. 1. Available: <https://doi.org/10.1186/s40537-023-00817-1>.
- [4] Z. Zhang, et al., "Hospitalized patients with heart failure: integrating electronic healthcare records and external outcome data v1.3," *PhysioNet* (2022). Available: <https://doi.org/10.13026/5m60-vs44>.
- [5] A. Ilin, A. Fi, and T. Jaakkola, 2010. "Practical Approaches to Principal Component Analysis in the Presence of Missing Values." *Journal of Machine Learning Research*, vol. 11, pp. 1957–2000.
- [6] M.-L. Zhang and Z.-H. Zhou, 2007. "ML-KNN: A lazy learning approach to multi-label learning." *Pattern Recognition*, vol. 40, no. 7, pp. 2038–2048. Available: <https://doi.org/10.1016/j.patcog.2006.12.019>.
- [7] "sklearn.impute.KNNImputer-scikit-learn 0.23.1 documentation," *scikit-learn.org*. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.impute.KNNImputer.html>
- [8] M. Belgiu and L. Drăguț, 2016. "Random forest in remote sensing: A review of applications and future directions." *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 114, no. 114, pp. 24–31. Available: <https://doi.org/10.1016/j.isprsjprs.2016.01.011>.
- [9] Y.-Y. Song and Y. Lu, 2015. "Decision tree methods: applications for classification and prediction." *Shanghai archives of psychiatry*, vol. 27, no. 2, pp. 130–135. Available: <https://doi.org/10.11919/j.issn.1002-0829.215044>.
- [10] A. Natekin and A. Knoll, 2013. "Gradient boosting machines, a tutorial." Available: <https://doi.org/10.3389/fnbot.2013.00021>.
- [11] Oona Rainio, Jarmo Teuho, and Riku Klén, 2024. "Evaluation metrics and statistical tests for machine learning." *Scientific Reports*, vol. 14, no. 1. Available: <https://doi.org/10.1038/s41598-024-56706-x>.
- [12] L. Breiman, 2001. "Random Forests." *Machine Learning*, vol. 45, no. 1, pp. 5–32. Available: <https://doi.org/10.1023/a:1010933404324>.
- [13] J. R. Quinlan, 1986. "Induction of decision trees." *Machine Learning*, vol. 1, no. 1, pp. 81–106. Available: <https://doi.org/10.1007/bf00116251>.
- [14] J. H. Friedman, 2001. "Greedy Function Approximation: A Gradient Boosting Machine." *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232.